Machine Learning 2

PREDIKSI TINGGI GELOMBANG BERBASIS ENSEMBLE DAN REINFORCEMENT LEARNING

Presented by:
Aditya Putra Ananta (23083010048)
Alvino Hadiyan Pradipta (23083010050)

Table of Contents

1 Latar Belakang

2 Data Wrangling & Augmentation

3 Ensemble Learning

4 Reinforcement Learning

5 Hasil dan Analisis

6 Celah Pengembangan

7 Simpulan

Latar Belakang

Indonesia adalah negara kepulauan, di mana ⅔ wilayahnya nya merupakan perairan. Wilayah perairan Indonesia sering kali rawan terdampak oleh gelombang tinggi yang berpotensi membahayakan kapal/transportasi laut.

Gelombang laut yang muncul di laut tidak muncul secara instan, melainkan hasil dari akumulasi energi kinetik angin yang berembus selama kurun waktu tertentu.

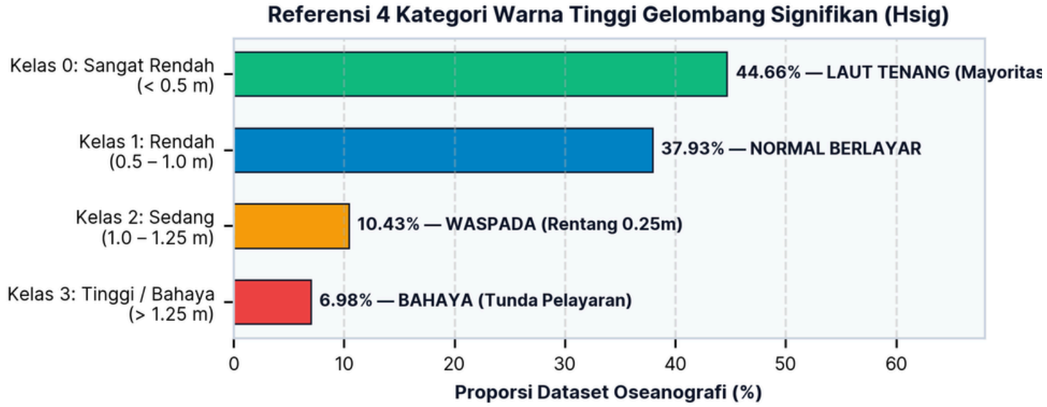


Parameter Dataset	Contoh Sampel	Keterangan
Timestamp (2019-2026)	2019-01-01 00:00	20.463 baris interval 3 jam
WindSpeed	12.4 Knots	Kecepatan Angin
WindDir	355.0°	Arah Angin
Hsig(m) [Target Utama]	**0.82 m**	**Tinggi Gelombang Signifikan**
Hmax(m)	1.54 m	Gelombang maks
WavePeriod	6.8 s	Periode
WindSea	0.65 m	Tinggi
WindSeaDir	350.0°	Arah Angin
PrimSwell	0.48 m	Gelombang Alun
CurrSpd	0.34 m/s	Kecepatan Arus Permukaan

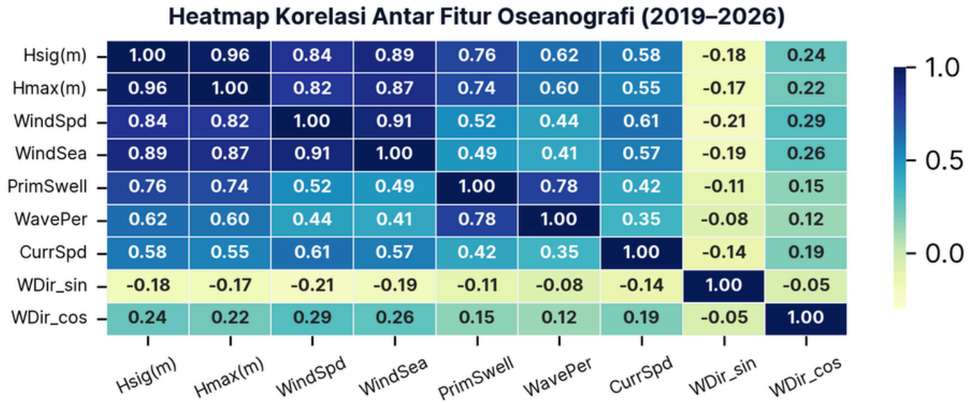
Mengapa Aturan Statis Tidak Cukup untuk Keselamatan Laut?

Masalah Operasional:

Pengkategorian (IF-Else) pada gelombang tinggi berarti kapal sudah dalam kondisi yang membahayakan, Hal ini menyebabkan kebutuhan akan prediksi T + 12 jam.



Standar Kategori Gelombang	Rentang Hsig	Proporsi Data	Status Operasional
Kelas 0 (Sangat Rendah)	< 0.5 m	44.66%	Aman Berlayar
Kelas 1 (Rendah)	0.5 - 1.0 m	37.93%	Normal Waspada
Kelas 2 (Sedang)	1.0 - 1.25 m	10.43%	Peringatan Dini
Kelas 3 (Tinggi / Bahaya)	**> 1.25 m**	**6.98%**	**Bahaya / Penundaan**





Data Wrangling & Augmentation

Data Wrangling merupakan salah satu proses pembersihan, transformasi, dan restrukturisasi data menjadi format yang lebih siap untuk dianalisis.

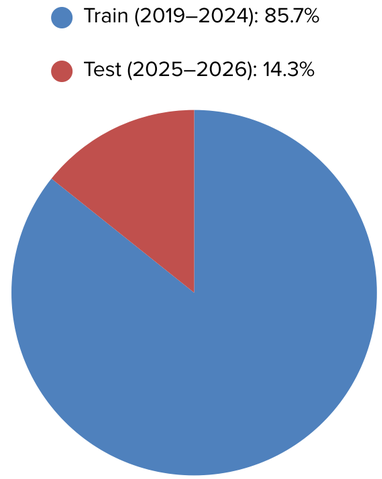
A. *Data Cleaning* dan Pengurutan *Timestamp*
B. Dekomposisi Vektor Trigonometri
C. Rekayasa Momen Inersia
D. Pembentukan Target Masa Depan (*t + 12 jam*)
E. Pemisahan Data Kronologis (penanganan *data leakage*)

Data Augmentation merupakan teknik yang digunakan untuk mengatasi ketidakseimbangan jumlah sampel data serta memperkaya variasi data latih untuk mengurangi bias model.

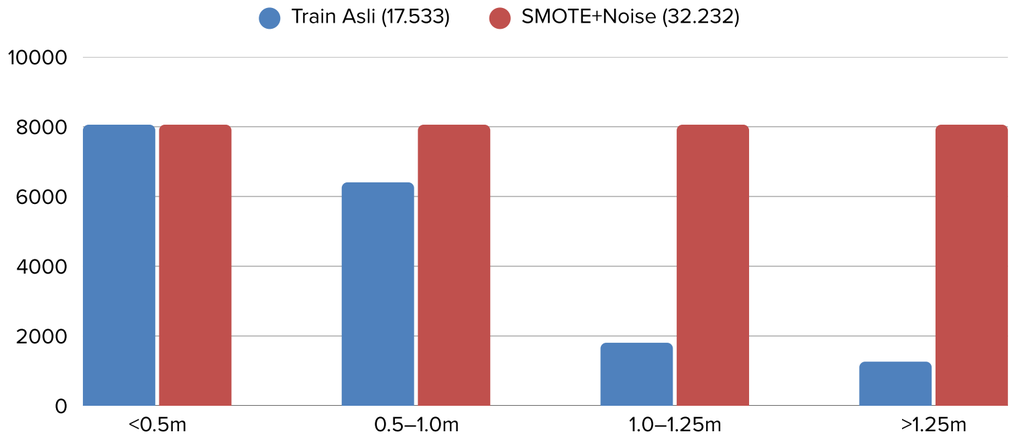
A. SMOTE
B. Injeksi *Noise* Sensor (Gaussian Noise Jittering)

Hasil Data Wrangling & Augmentation

- **Temporal Split:** Pisahkan Train (2019–2024) & Test murni (2025–2026) guna mencegah data leakage.
- **SMOTE Oversampling:** Kelas Tinggi (>1.25m: 7.21%) diseimbangkan menjadi 8.058 baris per kelas.
- **Gaussian Noise:** Jittering noise agar model tahan fluktuasi sensor di laut.

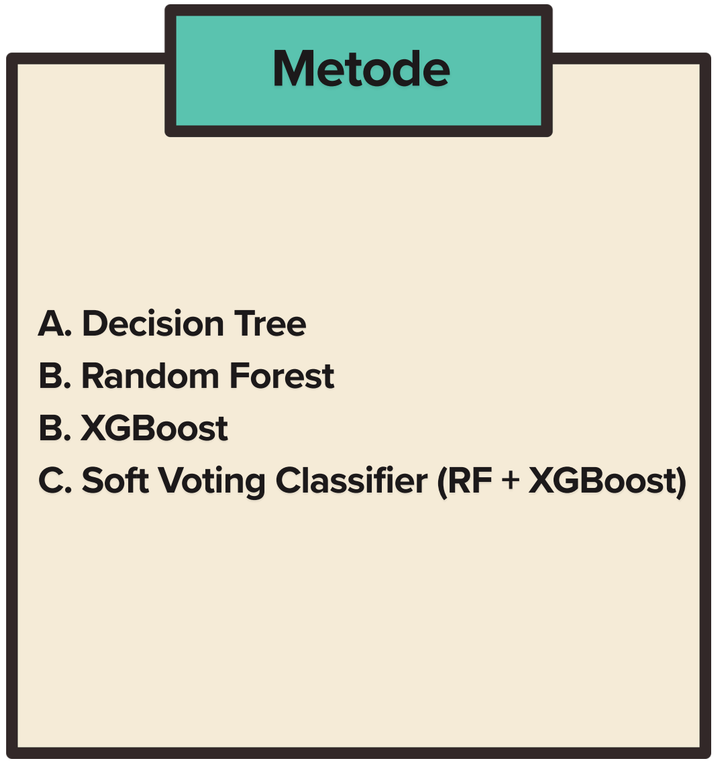


Kategori Gelombang	Train Asli	Train %	Train SMOTE	Data Test	Test %
Sangat Rendah (<0.5m)	8.058	45.96%	8.058	1.075	36.84%
Rendah (0.5–1.0m)	6.405	36.53%	8.058	1.352	46.33%
Sedang (1.0–1.25m)	1.806	10.30%	8.058	328	11.24%
Tinggi (>1.25m)	**1.264**	**7.21%**	**8.058**	**163**	**5.59%**
Total Sampel	**17.533**	**100%**	**32.232**	**2.918**	**100%**



Ensemble Learning

Ensemble Learning adalah metode dalam *machine learning* yang menerapkan penggabungan dua atau lebih algoritma untuk meningkatkan akurasi serta mengurangi kesalahan dan bias dibanding model tunggal. diterapkan untuk membantu meningkatkan akurasi analisis [1]. Hal ini penting dilakukan karena model tunggal cenderung mengalami *overfitting* dan sensitif terhadap *noise* yang ada pada data. Oleh karena itu, diperlukan penggabungan beberapa metode untuk menghasilkan prediksi yang lebih stabil dan tahan terhadap kondisi ekstrem.



[1] Sepbriant, G. D., & Utomo, D. W. (2024). Ensemble Learning pada Kategorisasi Produk E-Commerce menggunakan Teknik Boosting. JISKA (Jurnal Informatika Sunan Kalijaga), 9(2), 123-133.

Hasil Ensemble Learning

Model	Akurasi	F1-Macro	F1-Weighted	Recall
Decision Tree	0.869	0.827	0.872	0.791
Random Forest	0.891	0.852	0.892	0.92
XGBoost	0.901	0.867	0.902	0.883
Random Forest + XGBoost (Ensemble Voting)	0.899	0.866	0.901	0.907

Reinforcement Learning

1

Definisi

Reinforcement Learning merupakan penerapan *machine learning* yang bertujuan untuk membangun agen dalam pengambilan keputusan [2]. Penerapan *Reinforcement Learning* bertujuan untuk memperkuat hasil pemodelan, mengingat model dilatih secara *trial and error*. Dalam prosesnya, *Reinforcement Learning* memiliki *reward* dan *punishment* atas setiap hasil yang diberikan.

2

Metode yang Digunakan

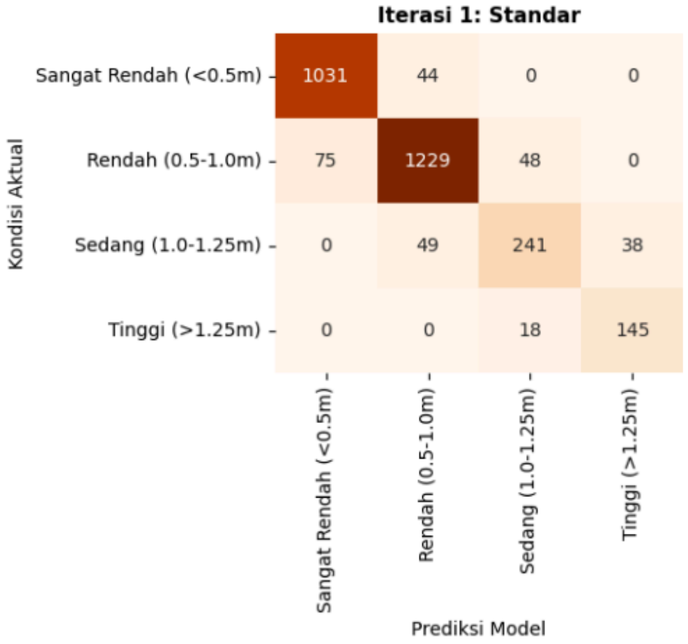
Proyek ini menggunakan :

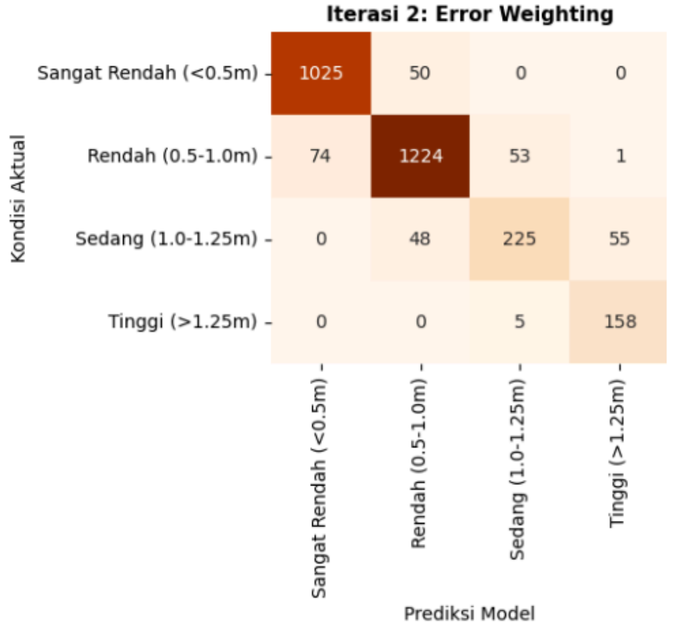
- **metode *iterative reinforcement*** yang tujuannya tidak hanya melatih model sekali, melainkan beberapa kali untuk memperkuat model.
- Metode Penambahan Data

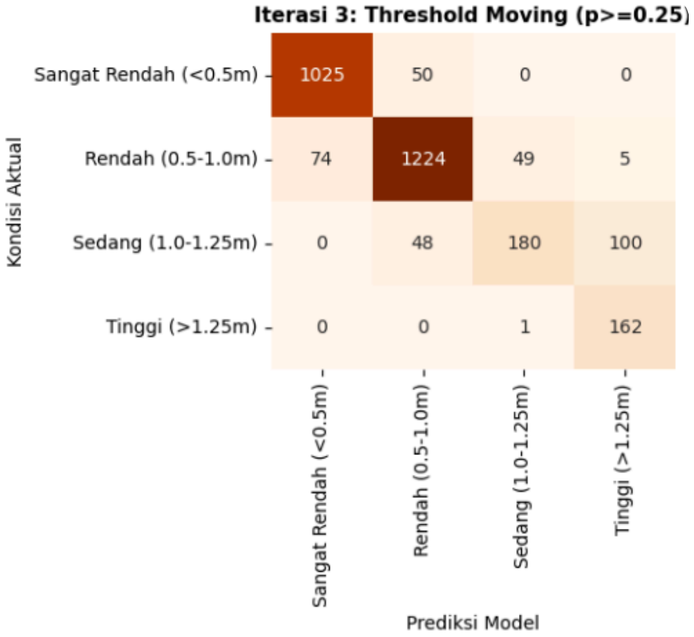
[2] Mehmood, S., & Syaharuddin, S. (2024). Reinforcement Learning for Automated Systems: Review of Concepts and Implementations. Jurnal Pemikiran dan Penelitian Pendidikan Matematika (JP3M), 7(2), 146-166.

Hasil Reinforcement Learning

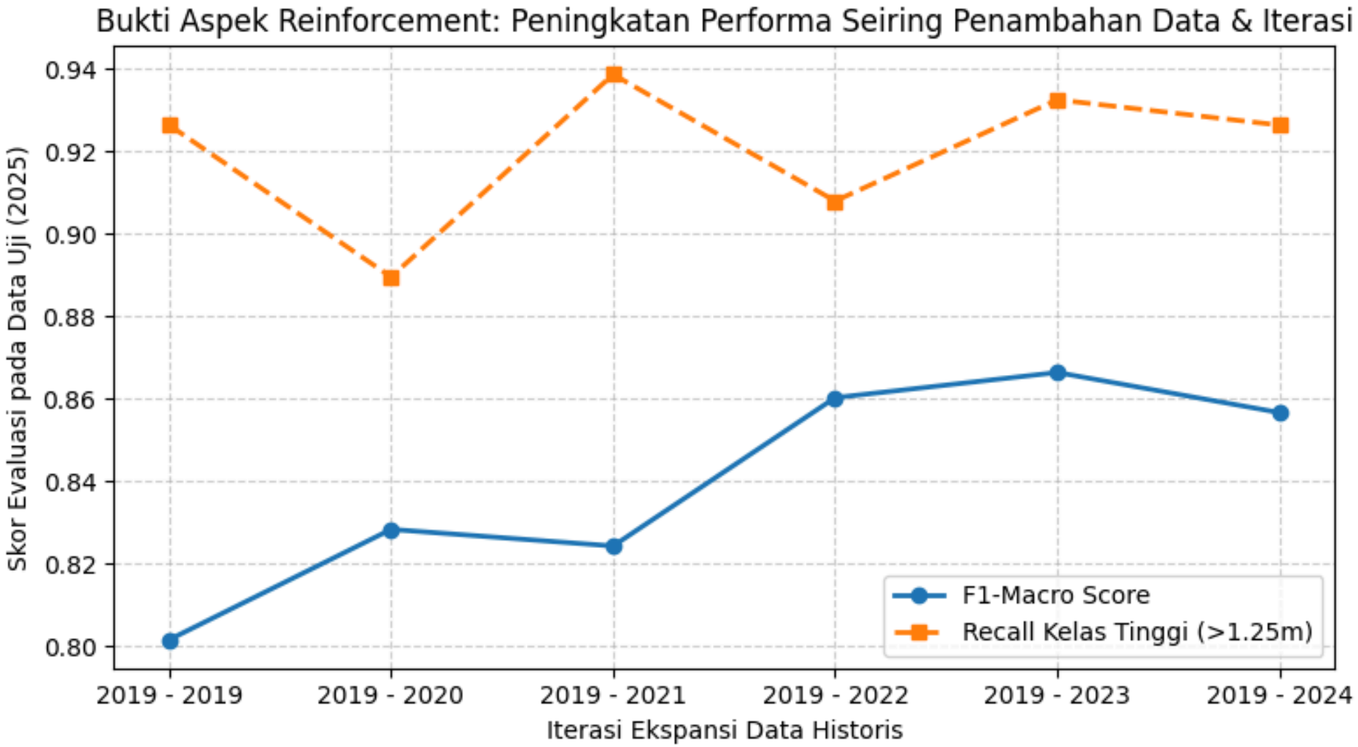
Siklus *Reinforcement*	F1-Macro	*Recall* Kelas Tinggi	Kasus Terlewat	Total Aktual Bahaya
Standar (Tanpa Penalti)	0.86	0.88	18	163
Error Feedback + Cost Weighting	0.85	0.95	5	163
Cost Weighting + Moving Threshold	0.81	0.99	1	163







Hasil Reinforcement Learning



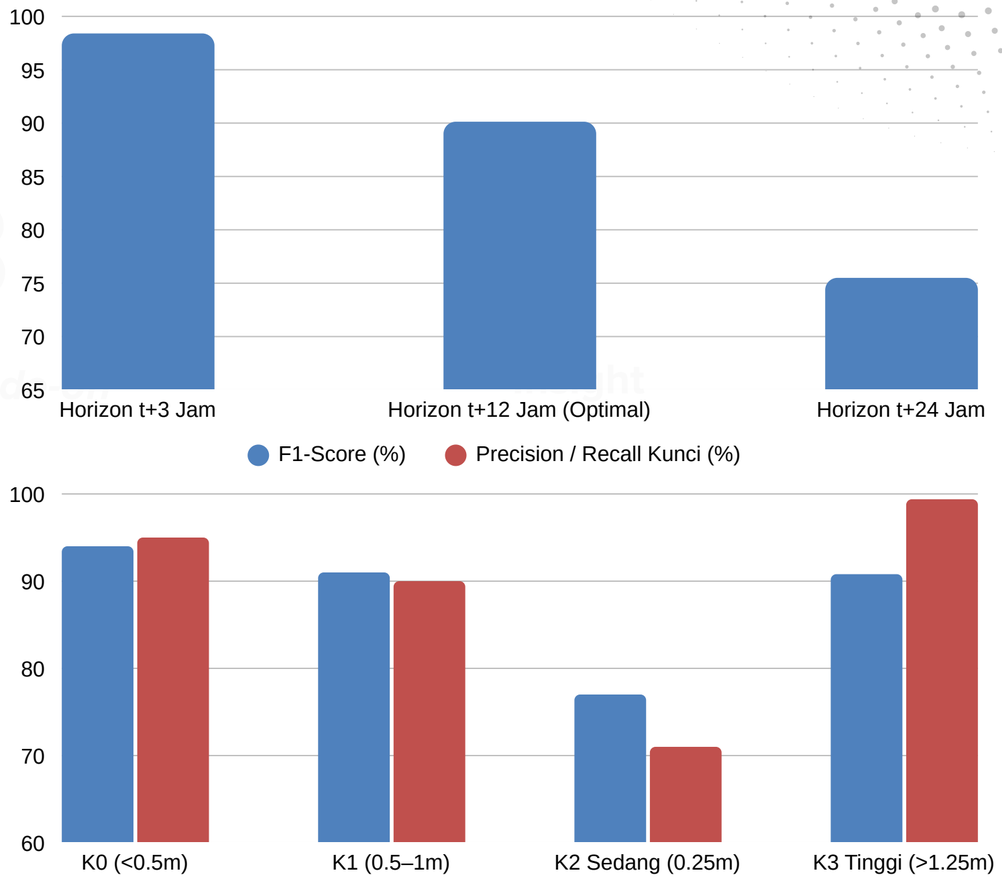
Rentang Data Latih	Jumlah Sampel Latih	F1-Macro (Uji 2025)
2019 - 2019	2912	0.801641
2019 - 2020	5841	0.828402
2019 - 2021	8762	0.824370
2019 - 2022	11683	0.860313
2019 - 2023	14604	0.866423
2019 - 2024	17533	0.856718

Hasil dan Analisis

1. Keterbatasan Kelas Sedang (1.0–1.25 m): Classification Report mencatat Kelas Sedang memiliki Precision terendah (0.71) dan Recall 0.83 (F1 = 0.77), di bawah Sangat Rendah (F1 = 0.94) dan Rendah (F1 = 0.91). Penyebab fisis: rentang tinggi gelombang sangat sempit (hanya 0.25 m) sehingga deviasi beberapa cm menggeser kelas.

2. Analisis Trade-Off (F1-Macro 86.55% ke 81.43%): Ambang p >= 0.25 memicu efek protektif (ombak 1.0–1.25 m ikut masuk peringatan >1.25 m) sehingga Precision turun. Di dunia maritim, menunda izin berlayar saat ombak sudah 1.15 m adalah mitigasi penyelamat nyawa.

3. Batasan Horizon Waktu & Pengembangan: Degradasi prediktabilitas atmosfer: horizon t+3 jam mencapai akurasi 98.4%, t+12 jam optimal di 90.13%, dan t+24 jam turun ke 75.5%.





Celah Pengembangan

A. Penerapan arsitektur *Deep Learning*
B. Penambahan variabel spasio-temporal berupa data citra.

Simpulan

Evaluasi izin keberangkatan kapal setiap 12 jam sekali. Hal ini didasari dari titik optimal pada saat horizon 12 jam, akurasi menghasilkan akurasi sebesar 90.13%.

Saat model menghasilkan prediksi gelombang tinggi (1.25 m), user dapat menginstruksikan penundaan keberangkatan untuk mengantisipasi potensi badai terlewat yang terklasifikasi dalam *False Negative*.

Pembagian kapasitas armada saat model menghasilkan prediksi gelombang sedang (1-1.25 m) untuk meminimalisasi *false alarm* bagi kapal tertentu yang bisa menahan gelombang di rentang tersebut.

Pengembangan penelitian seperti pelebaran rentang horizon waktu memerlukan penambahan variabel tambahan seperti data cuaca spasial dan tekanan udara berdasarkan pengukuran menggunakan barometer.

THANK YOU